

Universidade Tecnológica Federal do Paraná

Campus Apucarana

Bacharelado em Engenharia da Computação

Relatório - Análise em IA para Flores

Alunos:

Ana Carolina Ribeiro Miranda

Eiti Parruca Adama

Lucas Eduardo Pires Parra

Professor:

Dr. Rafael Gomes Mantovani

Setembro
2023

Universidade Tecnológica Federal do Paraná

Campus Apucarana
Bacharelado em Engenharia da Computação

Relatório - Análise em IA para Flores

Relatório do projeto proposto na disciplina de Sistemas Inteligentes 1 do Curso de Engenharia de Computação da Universidade Tecnológica Federal do Paraná, campus Apucarana como requisito parcial para aprovação da disciplina.

Aluno:

Ana Carolina Ribeiro Miranda

Eiti Parruca Adama

Lucas Eduardo Pires Parra

Professor:

Dr. Rafael Gomes Mantovani

Outubro
2023

Conteúdo

1	Resumo	1
2	Introdução	2
3	Trabalhos Relacionados	3
4	Metodologia	6
5	Resultados e discussões	10
5.1	Treinamento, Validação e Teste	10
5.2	Amostra da Interface Gráfica	13
6	Conclusão	19
7	Referências	20

1 Resumo

O objetivo deste projeto é desenvolver uma abordagem baseada em Inteligência Artificial (IA) para a identificação de flores, uma tarefa desafiadora devido à iluminação ou similaridades entre classes e seus formatos. As flores desempenham um papel essencial na nossa ecologia e cultura, e a sua identificação precisa é de grande importância em campos como a botânica, agricultura, conservação ambiental e até mesmo no interesse geral da apreciação da natureza, auxiliando também em seus cuidados. A análise é realizada por meio de um dataset com informações sobre 16 tipos de flores diferentes, por meio de uma rede neural convolucional (CNN).

2 Introdução

A relação entre seres humanos e plantas tem raízes profundas na história da civilização. As plantas desempenham um papel fundamental na nutrição, medicina, decoração e principalmente na manutenção do equilíbrio ambiental. No entanto, à medida que a urbanização e a vida moderna ganham terreno, o cuidado e o conhecimento sobre plantas, em especial as flores ornamentais, vêm se tornando mais desafiadores para grande parte da população.

A urbanização acelerada tem afastado as pessoas da natureza, limitando seu acesso ao conhecimento sobre plantas e resultando em cuidados inadequados e perdas desnecessárias no cultivo de flores ornamentais. A falta de tempo e o desconhecimento botânico dificultam a manutenção de plantas, impactando a beleza e vitalidade de nossos jardins.

Nesse contexto, a Inteligência Artificial (IA) emerge como uma ferramenta revolucionária com o potencial de redefinir o cuidado com as flores, tornando-o mais acessível, eficiente e sustentável. O objetivo central deste projeto é explorar as possibilidades da Inteligência Artificial como uma solução viável para auxiliar no cuidado de determinadas flores ornamentais. Especificamente, pretendemos desenvolver uma aplicação capaz de identificar diferentes espécies de flores, fornecendo informações essenciais para o cultivo e manutenção, como a frequência ideal de rega. Além disso, visamos, a longo prazo, estender a capacidade do sistema para identificar doenças e pragas, contribuindo assim para a prevenção e tratamento eficazes. Contudo, é crucial reconhecer que a classificação de flores é uma tarefa complexa, dada a considerável semelhança entre classes e as variações intraclasse. Imagens de flores capturadas em ambientes naturais ao ar livre enfrentam desafios de iluminação variável devido às condições climáticas. Além disso, questões como a transparência das flores e realces dos espécies podem afetar a precisão da classificação, acrescentando dificuldades devido à iluminação. Outros fatores, como variação no ponto de vista, oclusões e escala das imagens, também contribuem para a complexidade da tarefa de classificação de flores.

Esta pesquisa se justifica pela crescente necessidade de restaurar a conexão entre as pessoas e a natureza, bem como pela importância de promover práticas de jardinagem mais responsáveis e amigáveis ao meio ambiente. Além disso, o uso da IA para o cuidado de plantas pode ser uma ferramenta crucial para lidar com os desafios da urbanização e da falta de tempo, tornando a jardinagem uma atividade acessível e agradável para um público mais amplo.

Neste documento, vamos explorar os trabalhos relacionados, a metodologia, resultados e discussões dos desafios envolvidos como resultados e a conclusão do projeto de IA para identificação de flores.

3 Trabalhos Relacionados

Na busca por conhecimento e compreensão aprofundada do campo de identificação de flores por meio de tecnologias de inteligência artificial, nossa investigação se baseia em diversos trabalhos relacionados, dentre esses estudos, temos o trabalho intitulado “*Flower Classification Using Deep Convolutional Neural Networks*” de Hiary, Saadeh, Saadeh e Yaqub (2018), este estudo demonstrou notável sucesso na aplicação de redes neurais convolucionais profundas para a tarefa de classificação de flores com base em imagens destacando a eficácia das técnicas de aprendizado profundo, o trabalho de Hiary et al. fornece uma base sólida e valiosos *insights* que orientam a abordagem adotada em nosso próprio projeto de identificação de flores.

Para a classificação de flores do trabalho de Hiary et al. empregam uma combinação de atributos extraídos das imagens das flores, visando aprimorar o desempenho da classificação, por meio da cor, textura, forma e informações estatísticas, as quais desempenham um papel essencial na diferenciação entre diversas espécies de flores, muitas técnicas de classificação de flores se baseiam no aprendizado das características a partir de uma região segmentada da flor, o que contribui para a melhoria da precisão do sistema de classificação. Concluíram obtendo excelentes resultados em todos os conjuntos de dados, alcançando uma acurácia de 99, 98.5 e 97.1% na classificação.

Um estudo relacionado que também merece destaque é o trabalho intitulado “Texture Features and KNN in Classification of Flower Images,” realizado por Guru, Sharat e Manjunath. Este estudo emprega o classificador KNN (K-vizinho mais próximo) com base em características de textura para a classificação de imagens de flores. Os autores propõem um método que envolve duas etapas distintas: treinamento e classificação. Durante a fase de treinamento, um conjunto de imagens de treinamento é utilizado para extrair características de textura, que são então empregadas para treinar o sistema com o classificador KNN. Na fase de classificação, uma imagem de flor de teste é primeiramente segmentada, seguida pela extração das características de textura para fins de classificação. Essas características são, então, submetidas ao classificador KNN, o qual atribui rótulos às flores desconhecidas com base nas semelhanças encontradas no espaço de características. Os autores utilizaram um conjunto de dados com 1250 imagens, 50 em cada uma das 25 categorias, onde, aplicou-se no KNN as características da matriz de coocorrência de nível de cinza (GLCM), que obtiveram um desempenho máximo de 90,13%, em seguida, as características de Gabor obtiveram um desempenho de 79,80%, e por fim, a combinação de GLCM e Gabor obtiveram um desempenho de 98,88%.

O projeto “*Flower Classification Based on Single Petal Image and Machine*

Learning Methods”, conduzido por Yudong Zhang, Siyuan Lu e Zhihai Lu, foca na classificação de flores com base em imagens de uma única pétala por meio do emprego de técnicas de aprendizado de máquina. Foi utilizado quatro algoritmos de classificação: *SVM*, *W-kNN*, *K-ELM* e *DT*, para comparação. O projeto inclui o pré-processamento das imagens, onde foi utilizado o método Análise de Componentes Principais (PCA), removendo então os ruídos e normalizando o tamanho e o brilho, para garantir que as pétalas estivessem corretamente isoladas, além da extração de recursos (cor, textura, tamanho entre outros), treinamento e validação de modelos. De acordo com esse projeto, os resultados em 157 imagens de flores de três categorias indicaram que o *W-kNN* alcançou a maior precisão, com 99,4%, sugerindo que o método proposto é eficaz na identificação de categorias de flores.

Lin Shi, Zhigang Li e Dingli Song apresentaram um estudo intitulado “*A Flower Auto-Recognition System Based on Deep Learning*”, este estudo propõe um método mais rápido para retreinar a rede CNN baseada no Inception-V3 com um conjunto de dados menor, a fim de alcançar uma precisão superior em comparação com alguns métodos tradicionais de extração de recursos. O objetivo central é melhorar a taxa de reconhecimento e reduzir os requisitos de *hardware* do sistema e o tamanho do conjunto de treinamento. O processo envolve a conversão da imagem do usuário para o formato Tfrecord, que é recomendado oficialmente pelo TensorFlow, esse formato permite o armazenamento eficiente de dados de imagem e rótulos em arquivos binários, facilitando operações de cópia, movimentação, leitura e armazenamento no *TensorFlow*. Durante o treinamento da rede, os dados no formato Tfrecord são carregados em uma fila, estabelecendo um sistema de filas que gerencia a entrada e saída de dados de forma eficiente e independente, otimizando o processo de treinamento do modelo. A imagem da flor no formato Tfrecord é processada por uma rede CNN pré-treinada no conjunto de dados FLOWERS32 para identificar a categoria da imagem. Em seguida, o rótulo é enviado para armazenamento em nuvem, permitindo que um dispositivo móvel receba automaticamente o nome da flor. Os resultados obtidos com 32 categorias de flores, com base nos conjuntos de dados *Oxford-17* e *Oxford-102*, demonstram uma precisão de classificação de cerca de 95%.

Por fim, um estudo relacionado relevante é o desenvolvido por Parvathy, Vrinda, Shahistha, Naeema e o Prof. Anju, intitulado “FLOWER RECOGNITION SYSTEM USING CNN”. Nesse estudo, eles propõem a utilização de redes neurais convolucionais (CNN) para o reconhecimento de flores, aplicando a implementação desse modelo em uma aplicação web, visando criar uma interface mais amigável, eles treinaram o modelo CNN com um subconjunto do conjunto de dados de flores *Oxford 102*, que originalmente consiste em 102 classes, com 40 a 200 imagens para cada flor. O subconjunto usado


para treinar o modelo inclui 24 classes de flores, com 150 imagens para cada classe, após a classificação, um arquivo CSV é importado e as informações pertinentes sobre a planta são apresentadas ao usuário. Esse estudo alcançou uma precisão geral de 90%, notavelmente, quando o modelo foi alimentado com uma imagem em tempo real de uma flor de hibisco capturada por uma câmera móvel, obteve-se uma precisão de 98,46%, demonstrando a eficácia do sistema proposto no reconhecimento de flores em cenários de uso prático com imagens de dispositivos móveis.

4 Metodologia

O presente trabalho utiliza das técnicas de aprendizado profundo, as redes neurais convolucionais (CNNs), devido à sua notável precisão em comparação com abordagens clássicas de aprendizado de máquina que dependem de características manualmente definidas. Neste estudo, ilustramos a aplicação em CNNs, combinados com o acesso a conjuntos de dados de flores de tamanho significativo, para abordar com robustez a tarefa de classificação de flores. Nosso método automatizado localizará a região contendo a flor em uma imagem e, em seguida, utiliza essas regiões recortadas para treinar um classificador CNN capaz de discernir entre diversas classes de flores. A detecção da região da flor é realizada identificando a menor caixa delimitadora que contorna automaticamente a flor segmentada.

Uma Rede Neural Convolucional (CNN) é composta por uma série de camadas de convolução e subamostragem, seguidas, se desejado, por camadas totalmente conectadas. Neste contexto, concentramo-nos nas CNNs bidimensionais (2D), para processar imagens 2D, embora as CNNs unidimensionais ou de dimensões superiores compartilhem conceitos semelhantes. Na entrada de uma camada de convolução, é fornecida uma imagem com dimensões ($r \times c \times n$), onde r representa o número de linhas, c o número de colunas e n o número de canais. A função da camada de convolução é treinar K filtros (ou *kernels*) com dimensões ($k_r \times k_c \times k_n$). Seguindo uma ideia semelhante a figura 1.

Figura 1: Rede Neural Convolucional (CNN)



Fonte: Autoria própria

Optamos por utilizar uma Rede Neural Convolucional (CNN) em vez do KNN (K-vizinhos mais próximos) para o nosso projeto devido à complexidade inerente da tarefa, que envolve a detecção de características diversas como texturas e formas nas imagens das flores. As CNNs são especialmente adequadas para capturar informações detalhadas e hierárquicas a partir de imagens, o que é fundamental para uma identificação precisa de diferentes espécies de flores. Além disso, nossa abordagem se beneficia do amplo conjunto de dados disponível, permitindo que a CNN aprenda representações ricas e generalize eficazmente para flores não presentes no conjunto de treinamento. Em resumo, a escolha da CNN se baseia na capacidade dessa técnica de aprendizado profundo em lidar com tarefas desafiadoras de processamento de imagens, oferecendo maior potencial de sucesso na análise e classificação de flores.

Para nosso projeto, adquirimos o conjunto de dados do site *Kaggle*, intitulado “*Flowers*” e disponibilizado pelo usuário “l3l1ff”. Esse conjunto de dados incorpora imagens e informações obtidas de uma variedade de plantas que compartilham muitas características, mas também são diferentes em algum aspecto, nesse conjunto temos o total de 16 espécies de flores diferentes.

A linguagem de programação escolhida foi *Python*, devido à sua flexibilidade e robustez, além da vasta disponibilidade de bibliotecas voltadas para aprendizado de máquina e processamento de imagens. Algumas das biblio-

tecas cruciais incluídas no nosso ambiente de desenvolvimento são: *numpy* para manipulação eficiente de arrays, *pandas* para a gestão e análise de dados, *matplotlib* para visualização de resultados, *PIL (Python Imaging Library)* para operações com imagens, e a infraestrutura fornecida pelo *TensorFlow* e *Keras*, que são amplamente reconhecidas em aprendizado profundo. A combinação destas bibliotecas, juntamente com outras, possibilita a criação de uma solução robusta e eficaz para nossa aplicação de análise de flores, aproveitando a capacidade de *Python* em manipulação de dados e de processamento de imagens oferecido pelas bibliotecas selecionadas.

O código inicia importando as bibliotecas necessárias, e logo em seguida são definidos alguns parâmetros essenciais, como o diretório onde os dados das flores estão localizados, as dimensões desejadas para as imagens (150x150 pixels) e o tamanho do lote (*batch_size*) usado durante o treinamento da rede. Um gerador de dados é criado usando a classe *ImageDataGenerator* do *Keras*, que aplica várias transformações nas imagens, como escala de cores, rotação, zoom e espelhamento horizontal. Além disso, ele divide automaticamente os dados em conjuntos de treino e validação, sendo 80% para treino e 20% para validação.

Os dados de treino e validação são carregados usando os geradores de dados criados, que são obtidos a partir do diretório especificado e redimensionados para as dimensões desejadas, a *classe_mode* é definida como *'categorical'*, indicando que se trata de um problema de classificação com várias classes, os rótulos das classes e as contagens de amostras por classe nos conjuntos de treino e validação são extraídos para análise.

A estrutura da rede neural convolucional (CNN) é definida usando a classe *Sequential* do *Keras*. A arquitetura inclui camadas convolucionais seguidas por camadas de pooling para extração de características, uma camada *flatten* para achatar os dados e camadas densas (totalmente conectadas) para a classificação. A última camada utiliza a função *softmax* para produzir probabilidades de pertencer a cada classe.

O modelo é compilado especificando o otimizador (*'adam'*), a função de perda (*'categorical_crossentropy'* adequada para problemas de classificação com várias classes) e métricas (*'accuracy'* para monitorar o desempenho). O treinamento do modelo é realizado usando o método *fit*, onde são especificados os geradores de dados de treino e validação, o número de épocas e os passos por época, e após o treinamento, o modelo é salvo em um arquivo usando o método *save* e finalmente, as curvas de acurácia ao longo das épocas são visualizadas usando a biblioteca *Matplotlib*.

O segundo código, *identificar-projeto*, é para identificar diferentes tipos de flores a partir de imagens. Este programa foi desenvolvido para oferecer uma interface gráfica simples e interativa, permitindo que os usuários carreguem

uma imagem de uma flor e recebam a identificação da espécie, juntamente com informações básicas de cuidados para a flor identificada.

A estrutura do código começa com a configuração do ambiente, incluindo a importação de bibliotecas como *os*, *numpy*, *tkinter*, *PIL*, *tensorflow*, *matplotlib.pyplot*, e *tensorflow.keras*. Além disso, são definidos parâmetros essenciais, como os diretórios para os dados das flores (*data_dir* e *model_path*), o tamanho das imagens (*img_width* e *img_height*), e o tamanho do lote de imagens (*batch_size*).

Uma etapa crítica é o carregamento do modelo CNN previamente treinado. Isso é realizado por meio da biblioteca *TensorFlow*, onde o código tenta carregar o modelo especificado em *model_path*. Caso haja sucesso no carregamento, o programa está pronto para identificar flores.

A função *identify_flower(image_path)* é responsável por receber o caminho de uma imagem de uma flor. Dentro dessa função, a imagem é processada para se ajustar ao formato necessário para a entrada da CNN. O modelo carregado é então utilizado para fazer a predição da flor na imagem. Com base nas probabilidades calculadas para cada classe de flor, a função determina a flor mais provável e retorna seu nome, juntamente com um dicionário contendo as probabilidades de cada classe.

O programa inclui um conjunto predefinido de informações de cuidados (*care_information*) para diferentes tipos de flores. Essas informações são associadas aos nomes das flores para fornecer orientações básicas de cuidado ao usuário.

A interface gráfica é criada utilizando a biblioteca *tkinter*, apresentando botões para que o usuário escolha uma imagem e inicie o processo de identificação da flor. Ao selecionar uma imagem, a função *choose_image()* permite que o usuário navegue pelo sistema de arquivos e selecione a imagem desejada.

Ao processar a imagem selecionada, a função *process_image()* utiliza a função *identify_flower()* para identificar a flor na imagem, exibindo o nome da flor identificada e informações de cuidados associadas a ela. Além disso, um gráfico de barras com as probabilidades de identificação das diferentes flores é mostrado na interface gráfica.

5 Resultados e discussões

5.1 Treinamento, Validação e Teste

Realizou-se 3 treinamentos diferentes para a CNN, usando 10, 25 e 50 épocas, todos utilizando o mesmo dataset, com a mesma porcentagem de divisão de dados entre treino e validação, bem como a mesma seed. Na tabela abaixo, tem-se 15740 imagens separadas em 16 classes.

	Treino	Validação
Número de Classes	16	16
Amostras de Treino	12599	-
Amostras de Validação	3141	-
Contagem de Amostras por Classe (Treino)		
Astilbe	590	147
Calendula	783	195
California Poppy	818	204
Campanula	699	174
Coreopsis	838	209
Cravo	739	184
Daffodil	776	194
Dente de Leão	842	210
Girassol	822	205
Iris	844	210
Magnolia	839	209
Margarida	784	196
Margarida Amarela	800	200
Rosa	800	199
Tulipa	839	209
Water Lily	786	196

Tabela 1: Contagens de amostras por classe nos conjuntos de treino e validação.

Para cada treinamento, obteve-se os gráficos abaixo, que apresentam a acurácia dos conjuntos de teste e de validação, ao longo das épocas. Os gráficos são apresentados abaixo:




Figura 2: 10, 25 e 50 épocas

Em todos os três gráficos, a acurácia de treinamento e validação aumentam com o tempo. No entanto, a acurácia de treinamento é sempre maior que a acurácia de validação, o que é esperado, pois o modelo está sendo aplicado nos dados de treinamento. A diferença entre as duas acurácias está em um nível aceitável, porém pode indicar um overfitting se a diferença for muito grande, o que faria com que fosse necessário uma regularização, dropout ou aumento de dados.

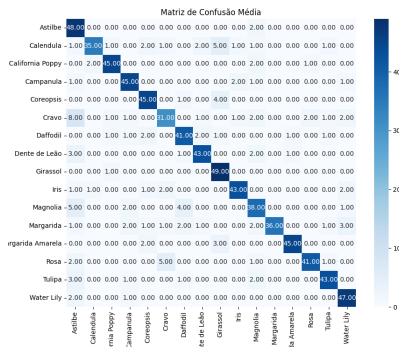
Para 10, 25 e 50 épocas, obteve-se os seguintes valores de acurácia:

Épocas	Acurácia no Teste	Acurácia na Validação
10	0.8632	0.7264
25	0.9429	0.7392
50	0.9719	0.7471


Tabela 2: Acurácia nos dados de teste e validação para diferentes épocas.

Para a avaliação de cada treinamento, utilizou-se um *dataset* contendo 50 imagens de cada classe, e se fez uma média para 5 execuções das predições, gerando suas matrizes de confusão e suas acurácias médias.

Abaixo, as figuras da matriz de confusão e das acurácias médias para 10 épocas:




(a) Matriz de confusão




(b) Acurácia

Figura 3: 10 épocas

Logo abaixo, as figuras da matriz de confusão e das acurácias médias para 25 épocas:



(a) Matriz de confusão



(b) Acurácia

Figura 4: 25 épocas

E finalmente, as figuras da matriz de confusão e das acurácias médias para 50 épocas:

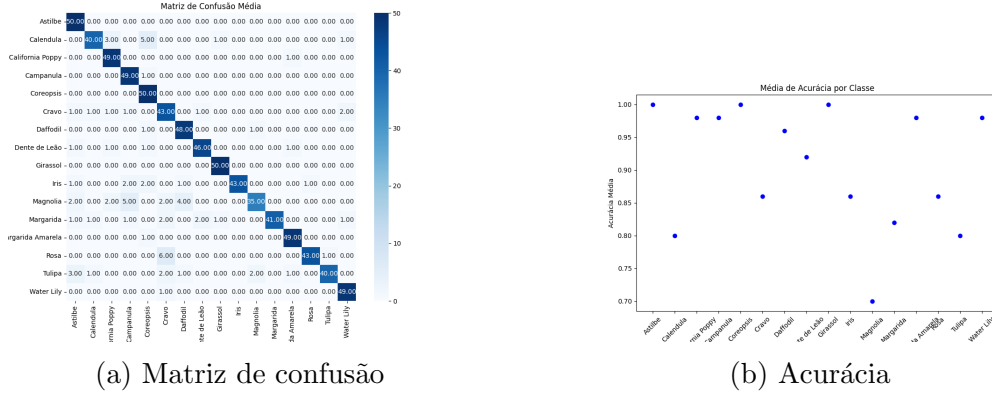


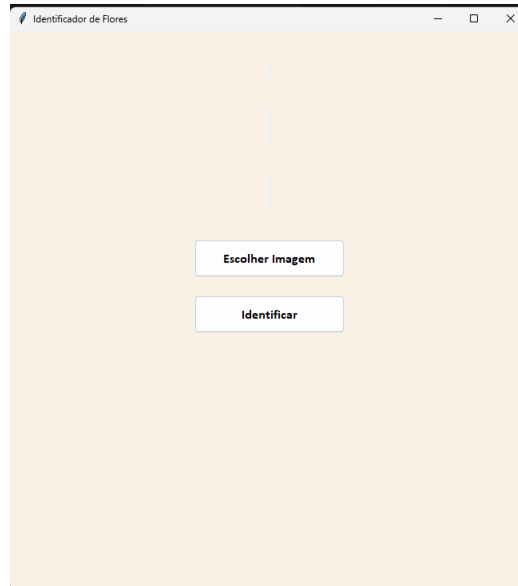
Figura 5: 50 épocas

Observa-se uma melhora quase geral na acurácia conforme se aumenta a quantidade de épocas de treinamento da CNN, porém, observa-se também algumas discrepâncias, como na Magnolia, que teve uma queda na quantidades de acertos quando testada a CNN de 50 épocas, obtendo um resultado pior que quando usado a CNN de 10 épocas. Isso pode indicar que o modelo está superestimando essa classe e precisa de ajustes para melhorar sua precisão. Isso pode ser alcançado através de técnicas como o balanceamento de classes ou a otimização dos hiperparâmetros do modelo, além de um aumento na quantidade dados para treino dessa classe em específico.

5.2 Amostra da Interface Gráfica

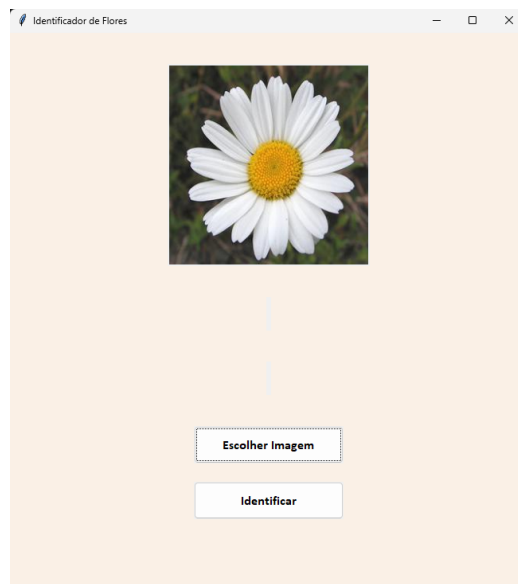
Após a geração do modelo treinado, a execução do código *identificar_projeto.py* proporciona ao usuário uma experiência interativa. Ao ser acionado, abre-se uma janela, conforme ilustrado na Figura 6, exibindo dois botões. O botão "Escolher Imagem" possibilita a seleção de uma imagem de flor no diretório desejado. Após a escolha da imagem, a interface será similar à apresentada na Figura 7.

Figura 6: Interface Inicial



Fonte: Autoria própria

Figura 7: Interface após escolhido a imagem

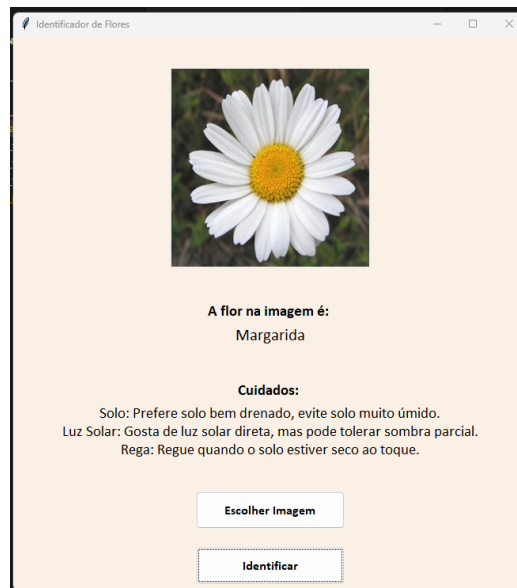


Fonte: Autoria própria

Ao acionar o botão "Identificar", o sistema identificará a flor presente na imagem, apresentando seu nome e informações sobre os cuidados necessários,

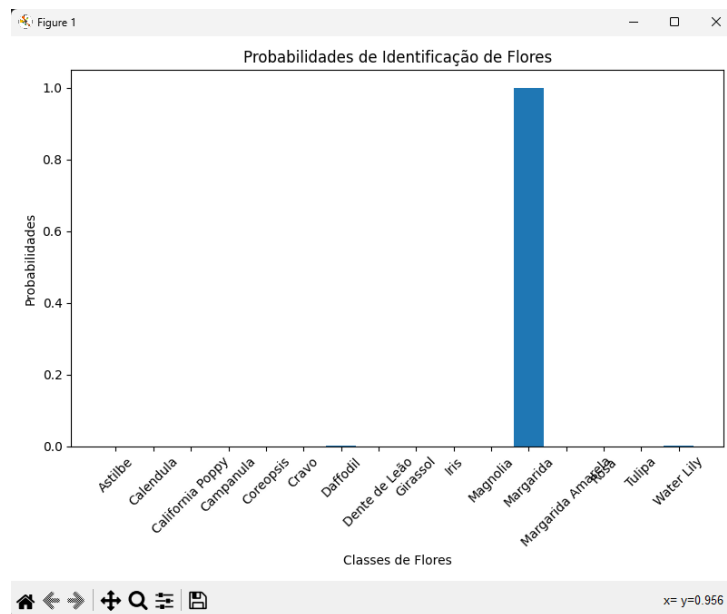
conforme exemplificado na Figura 8. Além disso, será aberta uma janela exibindo um gráfico com as probabilidades associadas às classes das flores para a imagem selecionada, tal como ilustrado na Figura 9.

Figura 8: Interface após a execução do botão "Identificar"



Fonte: Autoria própria

Figura 9: Gráfico de probabilidades da classe de flores



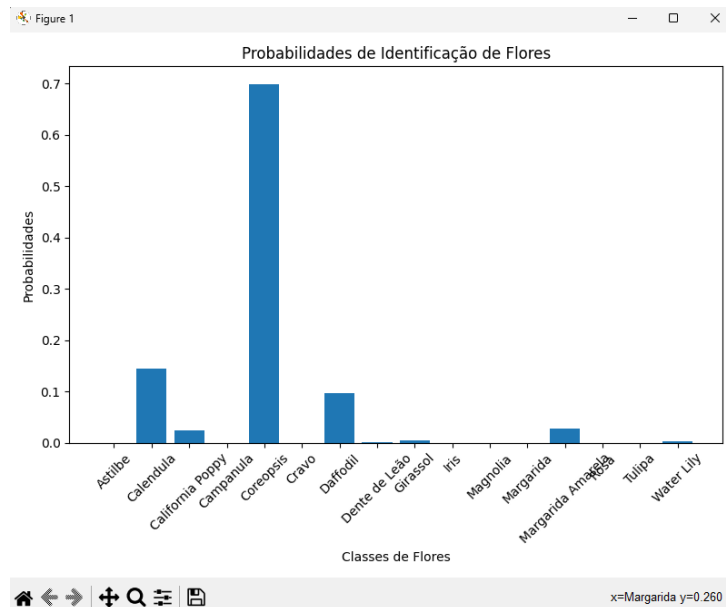
Quando uma imagem é selecionada em uma orientação diferente da original, como exemplificado na Figura 10, a precisão da identificação pode variar, dependendo do tipo de flor. No caso específico da margarida amarela invertida, não houve uma identificação correta, fazendo com que a precisão seja afetada com a orientação da imagem. Esse caso ocorreu com o modelo treinado de 10 épocas.

Figura 10: Margarida Amarela ao contrário



Fonte: Autoria própria

Figura 11: Gráfico da Margarida Amarela ao contrário



Fonte: Autoria própria

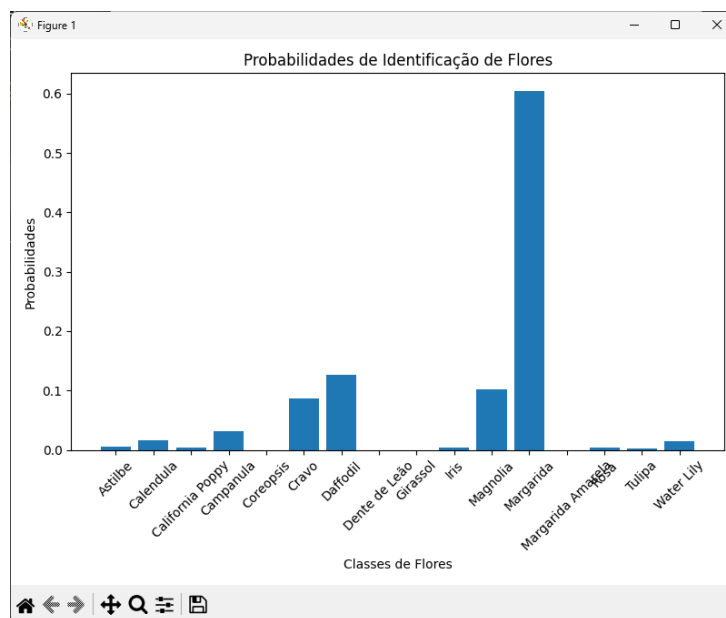
No entanto, ao aplicar um filtro na imagem, o resultado é completamente alterado, como demonstrado na Figura 13. Apesar disso, ao analisar as probabilidades, identificou-se uma semelhante, embora apenas a cor é diferente entre a margarida e a margarida amarela.

Figura 12: Margarida Amarela com filtro



Fonte: Autoria própria

Figura 13: Gráfico da Margarida Amarela com filtro



Fonte: Autoria própria

6 Conclusão

Neste trabalho, desenvolvemos uma Rede Neural Convolutacional (CNN) para a identificação de flores. Através do uso de técnicas avançadas de aprendizado de máquina, fomos capazes de treinar nosso modelo para reconhecer diferentes espécies de flores com precisão significativa.

A CNN provou ser uma ferramenta poderosa para este tipo de tarefa de classificação de imagens, sendo capaz de extrair automaticamente características importantes das imagens durante o processo de treinamento. Isso eliminou a necessidade de engenharia manual de características, tornando o processo mais eficiente.

As variações na orientação das flores afetam a precisão da identificação, enquanto a aplicação de filtros modifica drasticamente os resultados visuais. Entretanto, o sistema demonstrou capacidade em reconhecer similaridades estruturais entre as flores, mesmo quando apenas a cor diferia e usando um modelo com 10 épocas. Isso indica uma relativa robustez na identificação baseada em características fundamentais das flores, apesar das variações introduzidas pela orientação ou filtros.

Realizamos vários testes para avaliar o desempenho do nosso modelo, e os resultados foram promissores. No entanto, como qualquer projeto de aprendizado de máquina, há sempre espaço para melhorias. Futuras direções para este trabalho podem incluir o ajuste fino do modelo para aumentar ainda mais sua precisão, a expansão do conjunto de dados para incluir mais variedades de flores, ou a aplicação desta CNN a outros problemas de classificação de imagens.

Em conclusão, este trabalho demonstra o potencial das CNNs na identificação de flores e fornece uma base sólida para futuras pesquisas nesta área. Acreditamos que, com mais desenvolvimento, essa tecnologia poderia ter aplicações significativas em áreas como a botânica, a agricultura e até mesmo o comércio de flores.

7 Referências

DEEPAKSHI MAHAJAN. Flower Recognition Using Convolutional Neural Network. Última atualização: 24 Fev, 2023. Disponível em: <https://projectgurukul.org/flower-recognition-using-cnn/>. Acesso em: 19 de Outubro.

GURU, D. S.; SHARATH, Y. H.; MANJUNATH, S. Texture features and KNN in classification of flower images. IJCA, Special Issue on RTIPPR (1), p. 21-29, 2010. Disponível em: https://www.researchgate.net/publication/202430559_Texture_Features_and_KNN_in_Classification_of_Flower_Images. Acesso em: 19 de Outubro.

HIARY, H.; SAADEH, H.; SAADEH, M.; YAQUB, M. Flower classification using deep convolutional neural networks. IET Comput. Vis., vol. 12, p. 855-862, 2018. Disponível em: <https://doi.org/10.1049/iet-cvi.2017.0155>. Acesso em: 19 de Outubro.

KAGGLE. Flowers. Autor: l3l1ff (Owner). Disponível em: <https://www.kaggle.com/datasets/l3l1ff/flowers/data>. Acesso em: 19 de Outubro.

LU, S.; LU, Z.; CHEN, X.; WANG, S.; ZHANG, Y. Flower Classification Based on Single Petal Image and Machine Learning Methods. Disponível em: https://www.researchgate.net/publication/326705107_Flower_classification_based_on_single_petal_image_and_machine_learning_methods. Acesso em: 19 de Outubro.

PROJECT GURUKUL. Flower Recognition using CNN. Disponível em: <https://projectgurukul.org/flower-recognition-using-cnn/>. Acesso em: 19 de Outubro.

SHI, L.; LI, Z.; SONG, D. A Flower Auto-Recognition System Based on Deep Learning. IOP Conference Series: Earth and Environmental Science, Volume 234, 6th Annual 2018 International Conference on Geo-Spatial Knowledge and Intelligence, 14–16 December 2018, Hubei, China. In: IOP Conf. Ser.: Earth Environ. Sci. 234 012088, 2019. Disponível em: <https://iopscience.iop.org/article/10.1088/1755-1315/234/1/012088/pdf>. Acesso em: 19 de Outubro.